

	Curso	SI
	Período/Semestre	7º Período / 2026-1
	Disciplina	Temática em Mineração de Dados
	Nome	Arthur Faria Estrela, Ricardo Issa de Sousa , Sávio Issa de Sousa
	Data:	20 / 03 / 2026

Relatório Técnico: Modelo de Predição de Risco de Crédito

Objetivo do Projeto

Desenvolver um modelo preditivo robusto capaz de identificar clientes com alta probabilidade de inadimplência (default / calote) no mês seguinte, utilizando um histórico financeiro e demográfico.

1. Tratamento e Limpeza de Dados (Data Cleaning)

O que fizemos: Renomeamos colunas para facilitar a leitura, removemos a coluna ID e agrupamos categorias não documentadas ou muito raras (como 0, 4, 5 e 6 na variável EDUCATION e 0 e 3 em MARRIAGE) na categoria "Outros". Por fim, convertemos as variáveis para o tipo "Fator" (categorias).

Por que escolhemos fazer isso:

- * A coluna ID é apenas um identificador único. Se deixada no modelo, o algoritmo pode tentar encontrar padrões em números aleatórios (causando overfitting).

- * Categorias com pouquíssimos representantes ou não mapeadas no dicionário de dados geram "ruído matemático". Agrupá-las em "Outros" estabiliza o algoritmo.

2. Engenharia de Atributos (Advanced Feature Engineering)

O que fizemos: Criamos duas variáveis novas a partir dos dados crus:

- * Total_Meses_Atraso: Conta quantas vezes o cliente atrasou a fatura nos últimos 6 meses.

- * Racio_Pagamento_Divida: A proporção média de quanto o cliente pagou em relação a quanto ele devia.

Por que escolhemos fazer isso:

Algoritmos são ótimos com números, mas são melhores ainda quando damos a eles o contexto de "comportamento".

- * Em vez do modelo tentar adivinhar o impacto do mês 1, mês 2 e mês 3 separadamente, o `Total_Meses_Atraso` entrega um "Score de Inadimplência Crônica" pronto.

- * O Rácio mostra a intenção de pagamento. Quem paga 100% da fatura tem um perfil de risco drasticamente diferente de quem paga apenas o rotativo (mínimo). Isso dá um salto gigantesco na acurácia do modelo.

3. Particionamento Estratificado (Data Splitting)

O que fizemos: Dividimos a base em 80% para Treino e 20% para Teste usando a função `createDataPartition` do pacote `caret`.

Por que escolhemos fazer isso:

Ao contrário de um sorteio aleatório simples, o particionamento estratificado garante que a mesma proporção de caloteiros (aprox. 22%) seja mantida tanto na base de treino quanto na de teste. Isso impede que, por azar, o modelo seja treinado com poucos exemplos de inadimplentes.

4. Filtros de Redundância Matemática

O que fizemos: Aplicamos o filtro de Variância Nula (Near Zero Variance) e o filtro de Multicolinearidade (removendo colunas com correlação > 0.90).

Por que escolhemos fazer isso:

- * NZV: Colunas onde 99% dos valores são idênticos não ajudam o modelo a separar os bons dos maus pagadores. Removê-las poupa memória e tempo de processamento.

- * Multicolinearidade: Se duas variáveis dizem exatamente a mesma coisa (ex: o valor da fatura em dólares e o valor da mesma fatura em reais), o modelo fica "confuso" sobre qual variável é realmente importante. Remover duplicatas lógicas estabiliza a matemática da árvore de decisão.

5. Seleção Recursiva de Variáveis (RFE)

O que fizemos: Rodamos um motor de Random Forest temporário para testar diferentes grupos de variáveis e eliminar as menos importantes até sobrar apenas as que trazem o maior ganho de AUC.

Por que escolhemos fazer isso:

Muitas variáveis atrapalham mais do que ajudam (Maldição da Dimensionalidade). O RFE descobre empiricamente qual é o "Dream Team" (o time dos sonhos) de variáveis, removendo o lixo e deixando o modelo final mais leve, rápido e assertivo.

6. Modelagem Final: Random Forest + SMOTE + Validação Cruzada

O que fizemos: Transformamos todas as categorias de texto em variáveis Numéricas Binárias (Dummies 0 e 1). Em seguida, treinamos um modelo Random Forest usando Validação Cruzada de 10 dobras (10-Fold CV) e aplicamos a técnica SMOTE dentro da validação.

Por que escolhemos fazer isso:

- * As Dummies: O SMOTE funciona calculando distâncias geométricas entre clientes para criar dados falsos. A matemática geométrica exige números, não texto.

- * O Random Forest: É um dos algoritmos mais robustos para dados tabulares porque cria uma "floresta" com centenas de árvores de decisão que votam entre si, evitando que o modelo decore os dados (overfitting).

- * O SMOTE (dentro do trainControl): A base original é desbalanceada (temos muito mais bons pagadores do que maus). O modelo tenderia a chutar "Bom Pagador" sempre. O SMOTE cria "caloteiros sintéticos" para equilibrar a balança. Colocar isso dentro do trainControl evita o Vazamento de Dados (Data Leakage), garantindo que os dados sintéticos só existam durante o treino, e que as métricas de teste sejam 100% reais.

7. Avaliação e Otimização de Limiar (Threshold Tuning)

O que fizemos: Avaliamos as previsões no ambiente de teste com dois cortes: o padrão (50% de probabilidade) e o otimizado (38% de probabilidade). Também calculamos a curva ROC e a métrica AUC.

Por que escolhemos fazer isso:


- * No padrão (50%), o modelo prioriza a Acurácia Global.

- * O Limiar de 0.38 é uma decisão de Negócios. Para um banco, deixar passar um caloteiro (Falso Negativo) dá um prejuízo muito maior do que bloquear um bom pagador por engano (Falso Positivo). Reduzir o limite para 38% força o modelo a ser mais agressivo e "conservador" com o dinheiro do banco, aumentando a Sensibilidade (Recall) e pegando muito mais devedores.


- * A AUC (Area Under the Curve) é a prova definitiva de que o modelo é bom. Ela mede a capacidade do modelo de separar as classes, independente de usarmos o limite de 50% ou 38%.

Resumo do porquê ser um código Nível Master:

Em resumo, este código não se limita a "jogar os dados no algoritmo". Ele resolve problemas complexos de negócio e estatística através de Feature Engineering comportamental, prevenção de vazamento de dados (Data Leakage) durante o uso do SMOTE, uso de processamento paralelo, e otimização de limiares focada em redução de prejuízo financeiro para o banco.



Top 10 Variáveis (SMOTE + Eng. de Atributos)



Trade-off: Acurácia x Sensibilidade x Especificidade

