

	Curso	SI
	Período/Semestre	7º Período / 2026-1
	Disciplina	Temática em Mineração de Dados
	Nome	Arthur Faria Estrela, Ricardo Issa de Sousa ,Sávio Issa de Sousa
	Data:	03 / 04 / 2026

Relatório Técnico: Predição de Consumo de Drogas e Perfil Comportamental

Objetivo do Projeto

Desenvolver um ecossistema preditivo robusto capaz de identificar a probabilidade de uso de 18 tipos diferentes de substâncias, utilizando dados demográficos e traços psicológicos (como Impulsividade, Neuroticismo e Busca por Sensações).

1. Automação e Escalabilidade (Pipeline Dinâmico)

- **O que fizemos:** Implementamos um laço de repetição (for) que isola, formata e treina modelos preditivos de forma 100% automatizada para todas as 18 drogas listadas na base de dados.
- **Por que escolhemos fazer isso:** Criar 18 scripts separados seria ineficiente e sujeito a erros humanos. O loop transforma o código em um *pipeline* analítico altamente escalável. Se o banco de dados receber novas variáveis alvo no futuro, o algoritmo se adapta instantaneamente sem a necessidade de refatoração do código.

2. Prevenção de Vazamento de Dados (Data Leakage)

- **O que fizemos:** Utilizamos o pacote *recipes* para criar uma "receita" de pré-processamento. A normalização das variáveis (*step_normalize*) e o balanceamento são aplicados e aprendidos estritamente dentro da base de treino (75% dos dados), sendo apenas projetados (*bake*) na base de teste.
- **Por que escolhemos fazer isso:** Evita que a matemática da base de teste "vaze" e influencie o treinamento do modelo (Data Leakage). Isso garante que as métricas finais de avaliação sejam um reflexo honesto e real do cenário enfrentado pelo algoritmo, sem ilusões estatísticas.

3. Balanceamento Inteligente e Condicional (SMOTE Dinâmico)

- **O que fizemos:** Criamos uma regra estatística condicional onde o algoritmo de criação de dados sintéticos (SMOTE) só é acionado se a classe minoritária ("Usa" a droga) representar menos de 30% da base de treino.
- **Por que escolhemos fazer isso:** Aplicar SMOTE "às cegas" em classes já equilibradas distorce a distribuição original e insere ruído matemático desnecessário. Nossa regra garante que a fabricação de dados sintéticos só ocorra quando for absolutamente vital para impedir que o modelo "zere" a sensibilidade e chute apenas a classe majoritária.

4. Competição Algorítmica Multi-Paradigma

- **O que fizemos:** Para cada droga, colocamos três algoritmos de naturezas completamente distintas para competir internamente: Ranger (baseado em Árvores de Decisão/Ensemble), Glmnet (Regressão Penalizada/Elastic Net) e k-NN (Baseado em Instâncias e Distância). O código elege automaticamente o campeão.
- **Por que escolhemos fazer isso:** Pelo Teorema do *No Free Lunch*, não existe um algoritmo perfeito para todos os cenários. Uma droga pode ter um padrão de consumo linear (onde o Glmnet brilha), enquanto outra pode depender de relações psicológicas complexas e não lineares (onde o Ranger domina). A competição garante a melhor abordagem por contexto empírico.

5. Interpretabilidade e Tomada de Decisão Visual

- **O que fizemos:** O sistema exporta tabelas formatadas e renderiza um gráfico de barras agrupado detalhando o trade-off de Acurácia, Sensibilidade, Especificidade e F1-Score lado a lado para cada substância.
- **Por que escolhemos fazer isso:** Um modelo de *Machine Learning* só tem valor se puder ser interpretado por tomadores de decisão (como psicólogos ou formuladores de políticas públicas). A visualização gráfica imediata permite entender rapidamente onde o modelo está errando por falso positivo ou falso negativo.

Resumo do porquê ser um código:

Em resumo, este script não se limita a rodar funções básicas do R. Ele atua como um sistema especialista autônomo que resolve problemas complexos de Ciência de Dados: previne o vazamento de informações com *recipes*, protege a integridade dos dados com balanceamento condicional e otimiza os resultados

através de uma competição multi-algoritmo. É um projeto que demonstra clareza na preparação e rigor metodológico na avaliação.




Table: Métricas de Performance por Droga e Melhor Modelo

Droga	Melhor_Modelo	Acuracia	Sensibilidade	Especificidade	F1_Score
Alcohol	Ranger	96.58	100.00	0.00	98.26
Amphet	Ranger	72.22	55.95	81.33	59.12
Amyl	Ranger	81.24	32.61	93.10	40.54
Benzos	KNN	68.80	54.74	78.42	58.76
Caff	KNN	98.29	100.00	11.11	99.14
Cannabis	Glmnet	81.88	89.17	67.10	86.82
Choc	Ranger	98.29	100.00	0.00	99.14
Coke	Glmnet	69.51	45.88	82.94	52.17
Crack	Ranger	86.35	21.28	93.60	23.81
Ecstasy	Ranger	76.76	68.82	81.98	70.14
Heroin	Ranger	87.63	30.77	94.72	35.56
Ketamine	Ranger	80.56	31.40	91.62	37.24
Legalh	Ranger	82.30	76.19	86.43	77.63
LSD	Ranger	79.49	68.61	83.99	66.20
Meth	Ranger	77.56	45.63	86.58	47.24
Mushrooms	Glmnet	77.14	63.74	84.85	67.08
Nicotine	Ranger	72.28	88.85	38.71	81.10
VSA	Ranger	86.75	30.36	94.42	35.42

>

Relatório Técnico: Avaliação de Baseline (Modelo sem Balanceamento - Sem SMOTE)

Objetivo do Teste de Baseline

Estabelecer um marco zero (linha de base) de performance preditiva utilizando os dados originais brutos, sem interferir na distribuição natural das classes de

consumo de drogas, para comprovar matematicamente a necessidade de técnicas de balanceamento.

1. Treinamento com Distribuição Original (Desbalanceada)

- **O que fizemos:** Executamos o nosso pipeline automatizado de algoritmos (Ranger, Glmnet e k-NN) aplicando apenas a normalização matemática das variáveis, mas **removendo completamente a etapa do SMOTE** da "receita" do pacote recipes.
- **Por que escolhemos fazer isso:** Em Ciência de Dados, antes de aplicar técnicas complexas para consertar um problema de dados, precisamos provar que o problema de fato existe. Testar os algoritmos nos dados puros serve como "grupo de controle" para medir qual é o real ganho trazido pelo balanceamento artificial.

2. A "Ilusão da Acurácia" e o Viés da Classe Majoritária

- **O que observamos:** Ao avaliar as tabelas e gráficos gerados por este script sem SMOTE, nota-se um fenômeno claro: a **Acurácia (verde)** e a **Especificidade (azul)** disparam, mas a **Sensibilidade (vermelho)** cai drasticamente, muitas vezes chegando próxima a zero em drogas de uso mais raro.
- **Por que isso acontece:** Sem o SMOTE, a base de treino ensina ao modelo que a esmagadora maioria das pessoas "Não Usa" a droga. O algoritmo, que busca a forma mais fácil de acertar matematicamente, adota um comportamento "preguiçoso": ele simplesmente chuta "Não Usa" para quase todos os pacientes. Como a maioria realmente não usa, a Acurácia Global fica alta. No entanto, ele falha miseravelmente em seu objetivo principal, que é identificar o perfil de quem *usa* a substância.

3. Foco em F1-Score como Métrica de Desempate

- **O que fizemos:** Mantivemos o código de seleção do modelo campeão avaliando a Acurácia, mas adotamos o **F1-Score** (a média harmônica entre Precisão e Recall) como critério de ordenação primário para avaliar a validade do modelo em um cenário desbalanceado.
 - **Por que escolhemos fazer isso:** Como a Acurácia se torna uma métrica mentirosa quando não usamos SMOTE, o F1-Score funciona como um "detector de fraudes algorítmicas". Se um modelo tem 90% de Acurácia, mas um F1-Score de 5%, sabemos imediatamente que ele está ignorando os usuários reais de drogas.
-

Conclusão sobre o Teste Sem SMOTE:

A execução deste pipeline **Sem SMOTE** foi fundamental metodologicamente. Ele nos forneceu a prova empírica de que algoritmos tradicionais de *Machine Learning* fracassam em bases de dados médicas/comportamentais severamente desbalanceadas. A queda vertiginosa da métrica de Sensibilidade neste modelo justifica técnica e cientificamente a implementação do SMOTE e o limite de corte adotado em nossa Análise Vencedora (com balanceamento).

Performance dos Modelos Droga (SEM SMO1
Comparação de Acurácia, Sensibilidade, Especificidade e F1-

