

IF GOIANO · CAMPUS URUTAÍ · 7º PERÍODO / 2026-1

Arthur Faria Estrela, Ricardo Issa de Sousa, Sávio Issa de Sousa · 03/04/2026


Objetivo do Projeto

Desenvolver um ecossistema preditivo robusto capaz de identificar a probabilidade de uso de **18 tipos diferentes de substâncias**, utilizando dados demográficos e traços psicológicos como **Impulsividade, Neuroticismo e Busca por Sensações**.



1. Automação e Escalabilidade

PIPELINE DINÂMICO



O que fizemos


Implementamos um **loop for** que isola, formata e treina modelos preditivos de forma 100% automatizada para todas as 18 drogas.

Por que escolhemos

Criar 18 scripts separados seria ineficiente e sujeito a erros. O loop transforma o código em um *pipeline* analítico escalável que se adapta a novas variáveis-alvo sem refatoração.

2. Prevenção de Vazamento de Dados

DATA LEAKAGE



Utilizamos o pacote `recipes` para criar uma "receita" de pré-processamento. A normalização (`step_normalize`) e o balanceamento são aprendidos **estritamente na base de treino**, garantindo que a matemática do teste não influencie o modelo — eliminando ilusões estatísticas.

3. Balanceamento Inteligente e Condicional

SMOTE DINÂMICO


Regra Condicional

O SMOTE só é acionado se a classe minoritária ("Usa" a droga) representar **menos de 30%** da base de treino.

Por que escolhemos

Aplicar SMOTE em classes já equilibradas distorce a distribuição e insere ruído. A regra garante fabricação de dados sintéticos apenas quando vital para evitar que o modelo chute apenas a classe majoritária.


Com SMOTE



Dados sintéticos gerados, sensibilidade preservada.



Sem SMOTE



Sem alteração, distribuição original mantida.



4. Competição Algorítmica Multi-Paradigma

Pelo Teorema do *No Free Lunch*, não existe algoritmo perfeito para todos os cenários. Para cada droga, três algoritmos competem e o código elege automaticamente o campeão.



Ranger

Árvores de Decisão / Ensemble. Domina relações psicológicas complexas e não lineares.



Glmnet


Regressão Penalizada / Elastic Net.
Brilha em padrões de consumo lineares.



k-NN

Baseado em Instâncias e Distância.
Abordagem por similaridade entre perfis.

5. Interpretabilidade e Tomada de Decisão




O que fizemos

O sistema exporta tabelas formatadas e renderiza **gráficos de barras agrupados** com o trade-off de Acurácia, Sensibilidade, Especificidade e F1-Score para cada substância.

Por que escolhemos

Um modelo de *Machine Learning* só tem valor se puder ser interpretado por **psicólogos e formuladores de políticas públicas**. A visualização imediata revela rapidamente falsos positivos e negativos.

Performance dos Modelos – Com SMOTE



Destaque dos Melhores Modelos

O **Ranger** foi o algoritmo vencedor na maioria das substâncias. O **Glmnet** se destacou em Cannabis e Mushrooms, e o **k-NN** em Benzos e Caff.



Acurácia e Especificidade altas (80-100%) contrastam com Sensibilidade e F1-Score variáveis (0-99%), revelando o desafio de detectar usuários reais em bases desbalanceadas.

Avaliação de Baseline — Sem SMOTE

GRUPO DE CONTROLE

A "Ilusão da Acurácia"


Sem SMOTE, a **Acurácia e Especificidade** disparam, mas a **Sensibilidade** cai **drasticamente** — muitas vezes próxima a zero. O modelo adota comportamento "preguiçoso": chuta "Não Usa" para quase todos, pois a maioria realmente não usa.

F1-Score como Detector de Fraude

Com Acurácia de 90% mas F1-Score de 5%, sabemos que o modelo está **ignorando os usuários reais**. O F1-Score é a métrica honesta em cenários desbalanceados.

Com SMOTE


**Alta Sensibilidade:
identifica usuários
reais**



**F1-Score
Equilibrado**

Sem SMOTE

**Sensibilidade ≈ 0 :
ignora classe
minoritária**



**Viés da classe
majoritária**

Conclusão

Este script atua como um **sistema especialista autônomo** que resolve problemas complexos de Ciência de Dados:

- Previne vazamento
Com **recipes** aplicados estritamente na base de treino.
- Protege a integridade
Com balanceamento condicional SMOTE acionado apenas quando necessário (<30%).
- Otimiza resultados
Via competição multi-algoritmo (Ranger, Glmnet, k-NN) eleita empiricamente por droga.

✓ A queda vertiginosa da Sensibilidade no baseline sem SMOTE justifica técnica e cientificamente toda a metodologia adotada.

