

	Curso	SI
	Período/Semestre	7º Período / 2026-1
	Disciplina	Temática em Mineração de Dados
	Nome	Arthur Faria Estrela,Ricardo Issa de Sousa ,Sávio Issa de Sousa
	Data	08 / 04 / 2026

Relatório Técnico:

Modelo Otimizado de Predição de

Auto Imunidade Induzida por Drogas (DIA)

1. Objetivo do Projeto

O presente projeto tem como objetivo central desenvolver um modelo preditivo robusto, fundamentado em uma arquitetura de Stacking Ensemble que combina algoritmos de naturezas diferentes, como Random Forest, SVM e XGBoost. A meta é classificar e prever a autoimunidade induzida por drogas (DIA) utilizando descritores moleculares. A autoimunidade induzida por drogas é um problema de alta importância na toxicologia, sendo idiossincrático e de difícil previsão, onde fármacos ativam o sistema imune de forma errônea. Dessa forma, a abordagem busca superar as limitações da literatura atual, utilizando a sinergia de múltiplos algoritmos para lidar com dados toxicológicos complexos e prever reações adversas com alta precisão.

2. Tratamento e Limpeza de Dados (Data Cleaning)

Na fase inicial de preparação, procedeu-se à importação das bases de dados de treinamento e teste, compostas por descritores moleculares gerados pelo RDKit. O primeiro passo metodológico foi a remoção de colunas sem utilidade preditiva, especificamente as variáveis de identificação "SMILES" e "ID". A exclusão desses

identificadores diretos é crucial para evitar ruídos estruturais no aprendizado de máquina. Injetar informações não quantitativas causaria extrema confusão matemática aos modelos. Além disso, realizou-se a conversão rigorosa da variável alvo (Label) para o tipo Fator (X0 e X1), o que atende a um pré-requisito estatístico essencial no ambiente R para algoritmos de classificação supervisionada.

3. Pré-processamento, Engenharia de Atributos e Balanceamento

Para o pré-processamento, foi estruturada uma receita analítica metodológica focada no combate à chamada "maldição da dimensionalidade". Como os descritores extraem centenas de características físico-químicas, aplicou-se inicialmente a remoção de variáveis com variância quase zero e, em seguida, um filtro rigoroso que removeu descritores com correlação superior a 0.9. O embasamento para essa escolha é que, se duas variáveis explicam exatamente o mesmo comportamento molecular, manter ambas apenas introduz redundância e pode enviesar os pesos do modelo final. Sequencialmente, os dados foram normalizados, uma obrigação estatística incontornável, visto que modelos baseados no cálculo geométrico de distâncias, como o SVM, perdem totalmente a eficácia em escalas numéricas distintas.

Por fim, adotou-se o Oversampling através do método SMOTE para corrigir o viés da realidade farmacológica. Bancos de dados toxicológicos são naturalmente desbalanceados, com muito mais drogas seguras do que drogas que causam autoimunidade. Se o modelo fosse treinado com a base crua, a inteligência artificial tenderia a prever toda droga como "segura", ignorando o risco clínico real. O SMOTE contorna isso criando cópias sintéticas e inteligentes da classe minoritária durante o treinamento, forçando o algoritmo a aprender matematicamente os padrões que tornam uma droga perigosa.

4. Particionamento e Validação Cruzada

A estratégia de validação adotada consistiu na implementação de uma Validação Cruzada de 10 dobras (10-Fold CV) estratificada, com base na variável alvo. A aplicação rigorosa dessa estratificação assegura que a proporção original entre moléculas tóxicas e seguras seja mantida idêntica em todas as partições de treinamento e validação. O uso do 10-Fold CV demonstrou-se essencial para avaliar a estabilidade dos modelos base durante o processo de sintonia (Tuning) de hiperparâmetros, atuando como a principal barreira de proteção estatística contra o sobreajuste (overfitting) em cenários de alta complexidade.

5. Modelagem Final: Stacking Ensemble e Otimização de Limiar

A arquitetura foi construída a partir do treinamento paralelo de três algoritmos com naturezas estruturalmente diferentes, garantindo a captura de padrões não-lineares. O Random Forest foi selecionado por sua capacidade de reduzir a variância e ser altamente imune ao overfitting, enquanto o XGBoost atua na redução do viés, aprendendo de forma sequencial com os próprios erros. Em contrapartida, o SVM (Radial) projeta as características em múltiplas dimensões para encontrar uma fronteira geométrica que separe moléculas seguras das tóxicas.

A força dessa arquitetura reside no Stacking Ensemble. A genialidade dessa técnica não é apenas "juntar" as previsões, mas utilizar um meta-modelo (Regressão Lasso) para analisar os resultados base e atribuir um peso exato a cada algoritmo, aprendendo matematicamente em quem confiar dependendo da instância. Para maximizar a aplicabilidade do modelo, o corte de decisão (threshold) abandonou o padrão engessado de 0.50. Uma otimização empírica por força bruta foi aplicada, testando limiares de 0.01 a 0.99, encontrando o ponto ótimo em 0.26, o que permitiu maximizar a acurácia global adaptando-se à distribuição real das probabilidades do Ensemble.

6. Avaliação de Métricas e Conclusão Técnica

A análise dos resultados confirmou que, embora modelos preditivos individuais apresentem bons desempenhos, a integração deles no Ensemble ponderado trouxe a máxima sinergia matemática. Essa estratégia provou ser capaz de capturar padrões mais diversos na base de dados, culminando em uma métrica de AUC que superou não apenas os modelos isolados, mas também as acurácias reportadas pelos autores do estudo original de referência (InterDIA). Do ponto de vista da integridade metodológica, o uso estrito do framework tidymodels garantiu que transformações como oversampling e normalização fossem confinadas às dobras de treinamento, prevenindo o vazamento de dados (Data Leakage) e comprovando que a inteligência coletiva dos algoritmos gera previsões clínicas consideravelmente mais seguras.

7. Análise Visual dos Resultados

A eficácia técnica da abordagem é corroborada pela análise gráfica consolidada. A Curva ROC do modelo Ensemble ilustra a excelente capacidade de separação das classes de toxicidade. O gráfico de otimização de limiar comprova a necessidade e o acerto da calibragem fina por força bruta, demonstrando o pico exato de acurácia alcançado no corte de 0.26. Consequentemente, a Matriz de Confusão gerada sob esse limiar específico reflete um balanço inteligente, identificando Verdadeiros Negativos e Positivos de forma a minimizar criticamente o risco clínico de Falsos Negativos. Por fim, o gráfico de pesos dos modelos no Ensemble elucida a contribuição de cada algoritmo base (XGBoost, RF e SVM) após a penalização do modelo Lasso, atestando visualmente a harmonia do empilhamento algorítmico proposto.

8. Gráficos



