


IF GOIANO · CAMPUS URUTAÍ · 7º PERÍODO · 2026-1

Modelo Otimizado de Predição de Autoimunidade Induzida por Drogas (DIA)

Temática em Mineração de Dados · Arthur Faria Estrela, Ricardo Issa de Sousa, Sávio Issa de Sousa · 08/04/2026



Objetivo do Projeto

Desenvolver um modelo preditivo robusto baseado em **Stacking Ensemble** (Random Forest, SVM e XGBoost) para classificar e prever a **autoimunidade induzida por drogas** (DIA) utilizando descritores moleculares.

Problema


A DIA é idiossincrática e de difícil previsão — fármacos ativam o sistema imune de forma errônea.

Meta


Superar as limitações da literatura atual, incluindo o estudo de referência InterDIA.

Abordagem

Sinergia de múltiplos algoritmos para lidar com dados toxicológicos complexos e prever reações adversas com alta precisão.



Tratamento e Limpeza de Dados



Importação e Seleção

Bases de treinamento e teste com descritores moleculares gerados pelo RDKit. Remoção das colunas SMILES e ID para eliminar ruídos estruturais e evitar confusão matemática nos modelos.

Conversão da Variável Alvo

Label convertida para tipo Fator (X_0 e X_1), pré-requisito estatístico essencial no R para algoritmos de classificação supervisionada.

Pré-processamento e Engenharia de Atributos

1

Remoção de Variância Zero

Eliminação de descritores com variância quase zero para combater a maldição da dimensionalidade.

2

Filtro de Correlação

Remoção de descritores com correlação superior a 0,9, eliminando redundância e viés nos pesos do modelo.

3

Normalização

Obrigação estatística incontornável — modelos como SVM perdem eficácia em escalas numéricas distintas.


Balanceamento com SMOTE

O Problema do Desbalanceamento


Bancos toxicológicos são naturalmente desbalanceados: muito mais drogas seguras do que causadoras de autoimunidade. Treinar com a base crua levaria o modelo a prever toda droga como "segura", ignorando o risco clínico real.

A Solução: SMOTE

Oversampling cria **cópias sintéticas e inteligentes** da classe minoritária, forçando o algoritmo a aprender os padrões que tornam uma droga perigosa.



CROSS VALIDATING DATA



Particionamento e Validação Cruzada

10-Fold CV Estratificado

Validação cruzada de 10 dobras com estratificação pela variável alvo, mantendo a proporção original entre moléculas tóxicas e seguras em todas as partições.

Proteção contra Overfitting

O 10-Fold CV atuou como principal barreira estatística contra sobreajuste durante o **Tuning** de hiperparâmetros em cenários de alta complexidade.

Framework tidymodels


Transformações como oversampling e normalização foram confinadas às dobras de treinamento, prevenindo **Data Leakage** e garantindo integridade metodológica.

Arquitetura: Stacking Ensemble




Random Forest

Reduz a variância e é altamente imune ao overfitting.



XGBoost

Reduz o viés aprendendo sequencialmente com os próprios erros.



SVM (Radial)


Projeta características em múltiplas dimensões para encontrar a fronteira geométrica de separação.



Meta-Modelo Lasso

Atribui peso exato a cada algoritmo, aprendendo em quem confiar dependendo da instância.

Otimização de Limiar de Decisão




Força Bruta: 0,01 a 0,99

O corte padrão de **0,50** foi abandonado. Uma otimização empírica testou todos os limiares possíveis, encontrando o ponto ótimo em **0,26** — com acurácia de **0,85**.

Essa calibragem fina maximizou a acurácia global adaptando-se à distribuição real das probabilidades do Ensemble, reduzindo criticamente o risco de Falsos Negativos.

Resultados: Curva ROC e Matriz de Confusão




Curva ROC — Ensemble

A curva está significativamente acima da linha diagonal, demonstrando excelente capacidade de separação das classes de toxicidade. O AUC superou os modelos isolados e as acurácias do estudo **InterDIA**.

Matriz de Confusão (Limiar = 0,26)

Predição \ Verdade	X1	X0
X1	21	9
X0	9	81

Balanco inteligente que minimiza criticamente o risco clínico de Falsos Negativos.



Pesos dos Modelos e Conclusão Técnica

Sinergia Algorítmica

O Ensemble ponderado capturou padrões mais diversos, superando modelos isolados e o estudo InterDIA em AUC.

Contribuição dos Modelos

O gráfico de pesos elucida a contribuição de XGBoost, RF e SVM após penalização do Lasso, atestando a harmonia do empilhamento.

Integridade Metodológica

O framework tidymodels garantiu ausência de Data Leakage, comprovando que a inteligência coletiva gera previsões clínicas mais seguras.