

	Curso	SI
	Período/Semestre	7º Período / 2026-1
	Disciplina	Temática em Mineração de Dados
	Nome	Arthur Faria Estrela,Ricardo Issa de Sousa ,Sávio Issa de Sousa
	Data	10 / 04 / 2026

Relatório Técnico:

ILPD (Indian Liver Patient Dataset)

1. Objetivo do Projeto

O presente projeto tem como objetivo principal o desenvolvimento e a avaliação de modelos preditivos baseados em aprendizado de máquina para o diagnóstico de doenças hepáticas, utilizando o Indian Liver Patient Dataset (ILPD). A meta técnica estabelecida foi investigar o comportamento de algoritmos avançados frente a dados médicos altamente desbalanceados, buscando inicialmente superar a marca de 75,3% de acurácia global obtida por modelos lineares em literaturas recentes. Além da superação de métricas puras, o estudo visa realizar uma análise crítica profunda sobre a validade real da acurácia como principal balizador de sucesso em diagnósticos de saúde, propondo métodos matematicamente mais robustos e clinicamente interpretáveis.

2. Tratamento e Limpeza de Dados (Data Cleaning)

A base de dados ILPD é composta por 583 registros clínicos contendo variáveis bioquímicas e demográficas. Durante a fase de exploração inicial, constatou-se a integridade quase total do conjunto, com exceção da presença de valores ausentes localizados exclusivamente na variável referente à razão de Albumina e Globulina (A/G Ratio). Para preservar a volumetria da amostra e evitar a perda de correlações importantes presentes nas demais

colunas desses pacientes, optou-se pela imputação desses dados faltantes utilizando a mediana matemática da respectiva variável. Em seguida, os dados categóricos, como o gênero e o diagnóstico alvo, foram codificados numericamente para garantir total compatibilidade com as exigências dos motores de cálculo dos algoritmos de classificação avançada.

3. Pré-processamento, Engenharia de Atributos e Balanceamento

Para elevar a capacidade preditiva dos algoritmos, foi aplicada a Engenharia de Atributos (Feature Engineering), onde o conhecimento de domínio médico foi traduzido em matemática. A partir das colunas originais, foram criadas novas variáveis clínicas de alta relevância, como a Razão De Ritis (proporção entre as enzimas AST e ALT) e a Razão de Bilirrubina (Direta sobre Total), marcadores amplamente consolidados na literatura médica para o diagnóstico de dano hepático. Em vez de delegar o modelo a uma fórmula matemática pura que ignora a biologia e exclui colunas da base de dados de forma automatizada, a criação sintética desses marcadores guiada pelo contexto clínico provou ser a decisão mais robusta.

Devido à extrema variabilidade e aos picos assimétricos naturais em exames de sangue, os dados passaram pela transformação de Yeo-Johnson, seguida de centralização e escalonamento, mitigando o efeito de valores atípicos (outliers) sem deletar a informação vital que eles carregam. Diferente de abordagens rudimentares que simplesmente deletam outliers para forçar uma limpeza de dados, nosso estudo reconhece que, na área da saúde, o outlier geralmente é o próprio marcador de gravidade da doença. Essa transformação garantiu a normalização estatística das variáveis sem apagar as informações de pacientes que apresentam quadros agudos. No que tange ao desbalanceamento das classes, a estratégia evoluiu para permitir que o modelo aprendesse a distribuição natural, gerenciando o viés da classe majoritária diretamente na calibração das probabilidades durante a modelagem final.

4. Particionamento e Validação Cruzada

A metodologia de validação foi estruturada de forma rigorosa para evitar o fenômeno de sobreajuste (overfitting) e garantir comparações justas com trabalhos correlatos. Foi descartada a simples divisão estática de treino e teste (Hold-out), uma vez que conjuntos reduzidos geram alta volatilidade nas métricas finais. Em substituição, adotou-se a Validação Cruzada de 10 Vias (10-Fold Cross-Validation) aplicada sobre o espectro total de dados. Essa técnica garantiu que o algoritmo fosse treinado e testado em dez subconjuntos distintos e rotativos, extraíndo uma média de desempenho fundamentada e blindada contra flutuações aleatórias na distribuição das amostras.

5. Modelagem Final: Stacking Ensemble e Otimização de Limiar

A arquitetura preditiva final progrediu da experimentação de modelos lineares e de árvores isoladas para abordagens não lineares mais complexas, como Support Vector Machines com Kernel Radial (SVM-RBF) e técnicas de combinação de modelos (Ensemble). Contudo, a inovação técnica de maior impacto aplicada à modelagem foi a Otimização de Limiar (Threshold Tuning). Ao invés de aceitar a imposição binária padrão onde o algoritmo classifica um paciente como doente apenas se a probabilidade estatística ultrapassar 50%, o modelo foi instruído a calcular e expor o percentual exato de risco de cada paciente.

Na prática clínica, o custo de um Falso Negativo (mandar um doente grave para casa) é infinitamente maior do que o custo de um Falso Positivo (pedir mais exames preventivos). A Otimização de Limiar permitiu que o modelo fosse ajustado não para acertar cegamente o maior número de vezes, mas sim para equilibrar a Sensibilidade e minimizar erros fatais. A partir disso, simulou-se o impacto diagnóstico em todos os pontos de corte possíveis, permitindo calibrar a sensibilidade da inteligência artificial para maximizar matematicamente os acertos baseados no contexto médico real, e não em regras estáticas padrão.

6. Avaliação de Métricas e Conclusão Técnica

A aplicação combinada dessas metodologias culminou no que definimos como o "Insight de Ouro" desta pesquisa: a exposição do Paradoxo da Acurácia. Constatou-se que, para ultrapassar a barreira dos 75,3% e atingir a acurácia máxima, os algoritmos manipulavam as probabilidades rebaixando drasticamente o limiar de decisão, chegando a classificar pacientes como doentes mesmo com baixos níveis de evidência. Embora isso gerasse um modelo matematicamente superior na métrica global e excelente para triagem inicial de risco, revelou-se um desastre em termos de Especificidade, falhando criticamente em identificar pacientes saudáveis.


Identificamos que a busca obstinada pela Acurácia Global mascara o desempenho real dos algoritmos em classes altamente desbalanceadas. A conclusão técnica incontestável é que estudos anteriores focados exclusivamente em elevar a média de acurácia global neste dataset provavelmente mascararam essa falha grave de generalização. Portanto, para o diagnóstico médico, a acurácia é uma métrica ilusória, devendo o sucesso do modelo ser avaliado prioritariamente pela Área sob a Curva ROC (AUC-ROC). Essa métrica atua como o verdadeiro termômetro de sucesso, comprovando a capacidade real de separação do modelo entre doentes e saudáveis, oferecendo uma avaliação de confiança clínica muito superior.

7. Análise Visual dos Resultados


Para consolidar os achados matemáticos, a pesquisa contou com análises visuais que materializam o comportamento do algoritmo. O gráfico de otimização de limiar ilustrou com clareza cristalina a relação de troca (trade-off) em que a busca cega pela acurácia máxima sacrifica a especificidade do modelo. Em paralelo, a plotagem de Importância de Atributos validou o sucesso absoluto da Engenharia de Atributos, demonstrando que variáveis criadas sinteticamente com base no contexto biológico figuraram no topo da hierarquia de influência para a tomada de decisão da inteligência artificial. Essa transparência visual comprova que os modelos deixaram de atuar como "caixas pretas" e passaram a refletir

raciocínios clínicos interpretáveis.

8. Gráficos



3. Exames mais Importantes



4. Densidade das Probabilidades: Doentes vs Saudáveis

A linha vermelha tracejada é o seu Ponto de Corte Otimizado

