

	Curso	SI
	Período/Semestre	7º Período / 2026-1
	Disciplina	Temática em Mineração de Dados
	Nome	Arthur Faria Estrela, Ricardo Issa de Sousa, Sávio Issa de Sousa
	Data	27 / 03 / 2026

Relatório Técnico: Modelo Otimizado de Predição de Doença da Vesícula Biliar (Colelitíase)

1. Objetivo do Projeto

Desenvolver um modelo preditivo robusto, fundamentado no algoritmo Random Forest, capaz de auxiliar no pré-diagnóstico de cálculos biliares de forma não invasiva, utilizando 15 biomarcadores clínicos e laboratoriais.

O objetivo central é superar ou equiparar a acurácia de 84,12% estabelecida na literatura científica para o cenário de 80% de dados de treinamento, otimizando os hiperparâmetros do modelo para garantir alta capacidade de generalização clínica.

2. Tratamento e Limpeza de Dados (Data Cleaning)

Ações Realizadas: Importação da base de dados UCI Gallstone, padronização da nomenclatura das variáveis estruturais utilizando o pacote janitor e conversão rigorosa da variável alvo (gallstone_status) para o tipo Fator.

Justificativa: A padronização da nomenclatura mitiga erros de sintaxe decorrentes de caracteres especiais e espaços, garantindo a integridade do processamento no ambiente R. A conversão da variável alvo para Fator é um pré-requisito estatístico essencial, visto que

algoritmos de classificação supervisionada necessitam de rótulos discretos (ex.: Doente vs. Saudável) para a correta separação das classes, diferentemente de modelos de regressão contínua.

3. Particionamento Estratificado (Data Splitting)

Ações Realizadas: Divisão do conjunto de dados em 80% destinados ao Treinamento e 20% destinados ao Teste, implementando o particionamento estratificado (*strata*) com base na variável alvo.

Justificativa: A literatura de referência comprova que a proporção 80/20 promoveu a melhor convergência de desempenho preditivo entre os algoritmos testados. A aplicação da estratificação assegura que a distribuição original das classes seja rigorosamente mantida em ambos os subconjuntos, prevenindo vieses de amostragem e garantindo um treinamento fidedigno à realidade dos dados.

4. Pré-processamento, Engenharia de Atributos e Seleção de Variáveis (Feature Selection)

Ações Realizadas: Seleção metodológica de 15 variáveis preditoras clínicas e metabólicas baseada em testes empíricos de ganho de informação algorítmica. Sequencialmente, aplicou-se imputação pela mediana para tratamento de dados ausentes, normalização estatística (Z-score) para padronização de escalas numéricas e um filtro rigoroso de multicolinearidade, removendo variáveis com índice de correlação de Pearson superior a 0,90.

Justificativa Algorítmica e Estatística: A literatura científica de referência estabeleceu um bom precedente ao utilizar o algoritmo Random Forest para reduzir a dimensionalidade estrutural, limitando o modelo a 10 variáveis. No entanto, em nossos testes preliminares de Importância de Variáveis (avaliando a redução da impureza de Gini em cada nó das árvores), identificamos que o corte em 10 atributos descartava informações de alto valor preditivo. Decidimos expandir o limiar para as 15 variáveis mais importantes. Do ponto de vista estatístico, um subconjunto de 15 atributos não incorre na maldição da dimensionalidade, sendo processado com extrema eficiência pelo Random Forest. Para garantir a estabilidade matemática dessa expansão, o filtro de correlação (0,90) atuou como uma barreira de

segurança, assegurando que nenhuma das 15 variáveis fosse uma duplicata lógica de outra, eliminando redundâncias e ruídos que pudessem confundir as votações do algoritmo. A imputação pela mediana foi preferida à média por ser sabidamente mais resistente a valores extremos (outliers clínicos), comuns em exames laboratoriais.

Justificativa Clínica e Metabólica: A colelitíase (cálculos biliares) é uma patologia multifatorial complexa, impulsionada por disfunções no metabolismo lipídico, alterações na função hepática e quadros inflamatórios sistêmicos crônicos. Restringir o modelo a apenas 10 variáveis sub-representaria essa complexidade. Ao selecionar as 15 variáveis de topo apontadas pelo motor algorítmico, conseguimos fornecer à inteligência artificial um painel fisiológico holístico do paciente.

Mantivemos marcadores cruciais já validados pela literatura, como a Proteína C-Reativa (CRP) e a Vitamina D. Contudo, a expansão para 15 nos permitiu incluir marcadores bioquímicos decisivos que surgiram como altamente relevantes, tais como a Fosfatase Alcalina (ALP), a Hemoglobina, a Creatinina e o Colesterol HDL. Biologicamente, a Fosfatase Alcalina e o AST são biomarcadores diretos de estresse, lesão ou obstrução nas vias biliares e hepáticas. Simultaneamente, variáveis de composição corporal e perfil lipídico (HDL, Taxa de Gordura Corporal Total, Porcentagem de Obesidade) mapeiam diretamente a matriz de risco para a supersaturação da bile por colesterol, que é o mecanismo primário de formação das pedras.

Portanto, a escolha exata dessas 15 variáveis não foi arbitrária; ela reflete o ponto de equilíbrio matemático perfeito onde o modelo atinge o seu pico de capacidade de generalização e interpretabilidade médica, superando as abordagens minimalistas ao capturar toda a rede de interações metabólicas que levam ao desenvolvimento da doença.

5. Modelagem Final: Random Forest e Validação Cruzada

Ações Realizadas: Configuração do algoritmo Random Forest (*ranger*) parametrizado inicialmente com 500 árvores. Implementação de uma busca em grade (*Grid Search*) acoplada à Validação Cruzada de

10 dobras (10-Fold CV) para otimização sistemática dos hiperparâmetros `mtry` (variando de 2 a 8) e `min_n` (variando de 2 a 10).

Justificativa: O algoritmo Random Forest é amplamente documentado por sua eficácia em dados tabulares complexos, tendo alcançado a acurácia máxima nos estudos de referência. A otimização via *Grid Search* dentro de um ambiente isolado de Validação Cruzada garante o ajuste fino da complexidade matemática do modelo, mitigando significativamente o risco de sobreajuste (*overfitting*) e assegurando o melhor arranjo preditivo para o subconjunto de variáveis escolhido.

6. Avaliação de Métricas e Importância das Variáveis

Ações Realizadas: Validação do modelo final utilizando o conjunto de teste (20% de dados inéditos), com a extração das métricas de Acurácia Global, Sensibilidade, Especificidade e Área Sob a Curva ROC (AUC). Geração do gráfico de Importância de Variáveis (VIP).

Justificativa: No contexto de saúde, a avaliação restrita à Acurácia é insuficiente. A Sensibilidade consolida-se como uma métrica crítica para avaliar a capacidade do modelo de minimizar os Falsos Negativos (não detecção da doença). O gráfico VIP fornece a interpretabilidade exigida em aplicações médicas, elucidando empiricamente quais biomarcadores (como a Proteína C-Reativa e a Vitamina D) exercem maior impacto nas decisões geradas pela inteligência artificial.

7. Conclusão Técnica e Prevenção de Vazamento de Dados

Resumo Estratégico: A arquitetura desenvolvida eleva o rigor metodológico ao empregar o ecossistema *tidymodels*. Este framework assegura que as etapas de pré-processamento, como imputação e normalização, sejam calculadas e aplicadas estritamente a partir do conjunto de treinamento, prevenindo categoricamente o vazamento de dados (*Data Leakage*). A integração dessa arquitetura com a otimização de hiperparâmetros resulta em um modelo preciso, altamente generalizável e estruturado para fornecer suporte robusto à decisão clínica.

8. Gráficos

